MANUAL INTEGRAL

EcuabetExtractor

Extracción programada y manual con validación y reporte PDF

Guía de usuario · Instalación · Arquitectura · Mantenimiento

Versión del documento: 1.0 · Agosto 2026
Proyecto documentado: Extracción local mediante Chrome CDP
Autor y responsable del proyecto: Jimmy Toapanta
Fecha de revisión: 13/08/2026

Control del documento

Campo	Detalle
Proyecto	EcuabetExtractor
Alcance	Manual de usuario y referencia técnica en un único documento
Versión documentada	Extracción local mediante Chrome CDP
Rama de referencia	main
Estado	Herramienta Windows validada sin conexión con 17 pruebas
Público previsto	Usuarios autorizados para consulta deportiva y mantenedores Python
Responsable	Jimmy Toapanta
Última revisión	13/08/2026

Cómo usar este manual

La primera mitad acompaña a quien instala y utiliza la solución. La segunda explica cómo está construida, dónde guarda información y qué revisar antes de modificarla o desplegarla.

Este documento distingue lo que funciona hoy de las mejoras previstas. Cuando una integración depende de terceros, la guía lo indica y propone una verificación antes de operar con datos reales.

Contenido

Control del documento 2

Cómo usar este manual . . . 2

Contenido 3

El proyecto en pocas palabras 6

Propósito y alcance . . . 6

Qué resuelve . . . 6

Estado actual . . . 6

Alcance de esta entrega . . . 6

Fuera de alcance . . . 6

Preparación y puesta en marcha 7

Requisitos previos . . . 7

Instalación o incorporación . . . 7

Primera ejecución . . . 7

Operación paso a paso 8

Ejecutar desde la interfaz . . . 8

Descubrir y extraer por CLI . . . 8

Realizar una corrida manual por archivo . . . 8

Configurar la programación . . . 9

Tratar un mercado protegido . . . 9

Lista de control operativa . . . 9

Problemas frecuentes y recuperación 10

Uso responsable, privacidad y seguridad . . . 10

Preguntas habituales . . . 10
¿Necesita iniciar sesión? . . . 10
¿Usa Selenium? . . . 10
¿Qué días programa? . . . 10
Arquitectura y componentes **11**
Vista de arquitectura . . . 11
Responsabilidad de los componentes . . . 11
Configuración, datos e integraciones **12**
Parámetros importantes . . . 12
Persistencia y archivos generados . . . 12
Integraciones externas . . . 12
Flujos internos y decisiones de diseño **13**
Extracción reanudable . . . 13
Programación . . . 13
Criterios de diseño . . . 13
Desarrollo, pruebas y mantenimiento **14**
Entorno de desarrollo . . . 14
Estrategia de pruebas . . . 14
Registro, diagnóstico y soporte . . . 14
Mantenimiento recomendado . . . 14
Despliegue y continuidad **15**
Ruta de despliegue . . . 15
Respaldo y recuperación . . . 15

Criterios de aceptación 15

Límites conocidos y evolución **16**

Límites de la versión documentada 16

Hoja de ruta sugerida 16

Versiones y ramas 16

Entrega a otra persona **17**

Paquete de traspaso 17

Glosario breve 17

Cierre 17

01 · CONTEXTO

El proyecto en pocas palabras

EcuabetExtractor abre un Chrome local temporal, se conecta mediante Playwright por CDP y extrae información disponible sin automatizar un inicio de sesión ni evadir controles. Ofrece descubrimiento, extracción, validación, PDF, programación y una interfaz manual para seleccionar fecha y partidos.

Propósito y alcance

Convertir una consulta repetitiva en una salida estructurada, conservando evidencias de qué se obtuvo y qué no. Si una sección exige autenticación o no está disponible, la aplicación debe detenerse o marcar el dato como ausente; nunca fabricarlo.

Qué resuelve

- Descubrimiento y extracción por comandos claros.
- Navegador Chrome local con perfil temporal.
- Modo manual con selección de fecha y hasta 50 partidos.
- Validación de resultados y generación PDF.
- Programación limitada a jueves, viernes y sábado para jornadas objetivo.

Estado actual

La rama main se validó con 17 pruebas offline. config.json, perfiles, logs y outputs permanecen ignorados. La herramienta no usa Selenium, proxy, VPN, navegador remoto ni automatización de login. La carpeta física conserva el sufijo _fail, pero el nombre del proyecto y del futuro repositorio siguen siendo ecuabet-extractor.

Alcance de esta entrega

- Instalación o incorporación de la versión presente en la rama principal.
- Recorridos de uso, verificaciones y recuperación ante fallos habituales.
- Arquitectura, configuración, datos, integraciones, pruebas y despliegue.
- Límites conocidos y una ruta de evolución coherente con el estado del código.

Fuera de alcance

- Evitar autenticación, CAPTCHA, límites o condiciones del sitio.
- Inventar cuotas, árbitros o mercados cuando la fuente no los muestra.
- Publicar perfiles de Chrome, config.json, salidas, logs o datos obtenidos.

02 · GUÍA DE USUARIO

Preparación y puesta en marcha

La interfaz manual es la ruta más segura para empezar. Seleccione pocos partidos, observe la ventana de Chrome y valide la salida antes de instalar una tarea programada.

Requisitos previos

- Windows, Chrome local y Python 3.12.
- Dependencias del proyecto instaladas en .venv.
- Acceso lícito al sitio y cumplimiento de sus términos.
- Poppler o PDFTOPPM_PATH cuando la generación/validación PDF lo requiera.

Instalación o incorporación

1. Crear .venv e instalar dependencias.
2. Copiar el archivo de configuración de ejemplo como config.json local.
3. Revisar rutas de Chrome, salida y límites.
4. Ejecutar test con cinco partidos o abrir Abrir_EcuabetExtractor.cmd.
5. Validar JSON y PDF antes de programar.

```
py -3.12 -m venv .venv
.\.venv\Scripts\python -m pip install -r requirements.txt
Copy-Item config.example.json config.json
.\Abrir_EcuabetExtractor.cmd
.\.venv\Scripts\python.exe -m src.main test --matches 5 --after 13:00
```

Primera ejecución

1. Abrir la GUI y elegir una fecha de prueba.
2. Seleccionar entre 1 y 5 partidos.
3. Iniciar y observar que Chrome usa un perfil temporal.
4. Esperar validación y abrir la carpeta de salida.
5. Comparar al menos un mercado con la fuente visible y revisar el PDF.

Señal de que todo quedó bien: la ejecución termina con JSON validable y PDF legible, distingue campos ausentes y no solicita ni automatiza credenciales.

Operación paso a paso

Los recorridos siguientes están escritos para una jornada real de trabajo. Antes de confirmar una acción masiva, conviene validar primero un caso de prueba y revisar el resultado.

Ejecutar desde la interfaz

1. Abrir Abrir_EcuabetExtractor.cmd.
2. Elegir fecha y cantidad de 1 a 50 partidos.
3. Iniciar la extracción y no cerrar el Chrome temporal.
4. Seguir progreso y mensajes.
5. Abrir salida/PDF y ejecutar validación.

Resultado esperado: la carpeta de fecha contiene artefactos coherentes y la interfaz informa cualquier partido incompleto.

Descubrir y extraer por CLI

1. Ejecutar python -m src.main discover.
2. Revisar la lista descubierta.
3. Usar extract-next para avanzar de forma controlada.
4. Consultar status entre lotes.
5. Construir y validar el PDF al terminar.

Resultado esperado: cada paso es reanudable y el estado muestra qué queda pendiente.

Realizar una corrida manual por archivo

1. Crear mis_partidos.txt con entradas admitidas.
2. Ejecutar manual-run con fecha explícita.
3. Consultar manual-status.
4. Ejecutar manual-validate.
5. Conservar solo salidas autorizadas fuera de Git.

Resultado esperado: el conjunto manual no modifica la programación automática.

Configurar la programación

1. Probar run-scheduled manualmente.
2. Confirmar zona horaria y calendario.
3. Ejecutar schedule con permisos de Windows.
4. Revisar la tarea creada.
5. Observar el primer jueves, viernes o sábado y retirar si no corresponde.

Resultado esperado: solo se descubren jornadas viernes/sábado/domingo desde los días admitidos.

Tratar un mercado protegido

1. Detectar que el detalle requiere login o no está visible.
2. No introducir ni automatizar credenciales.
3. Registrar el mercado como no disponible.
4. Continuar solo con información pública permitida.
5. Reflejar la ausencia en validación y PDF.

Resultado esperado: la salida no contiene datos inventados ni un intento de eludir acceso.

Lista de control operativa

- Trabajar primero con datos de prueba cuando se cambie la configuración.
- Confirmar el resultado antes de ejecutar acciones masivas o irreversibles.
- Registrar fecha, entrada, salida y mensaje exacto cuando ocurra un error.
- Cerrar sesiones y proteger credenciales al terminar la jornada.

Problemas frecuentes y recuperación

Si algo falla, conserve el mensaje exacto, la hora y la acción que lo produjo. Esa información suele ser más útil que reinstalar o borrar la configuración sin diagnóstico.

Síntoma	Causa probable	Qué revisar
Chrome no abre	Ruta, versión o perfil bloqueado	Revisar config y cerrar procesos temporales huérfanos.
CDP no conecta	Puerto, arranque o firewall local	Observar comando de Chrome y endpoint local.
No descubre partidos	Día, hora, cambio de página o contenido ausente	Probar manualmente y revisar selector sin forzar login.
Mercados incompletos	Detalle protegido o estructura diferente	Marcar ausente y actualizar extractor solo con acceso permitido.
PDF no se genera	Poppler/PDFTOPPM_PATH o datos inválidos	Validar JSON y ruta pdftoppm.
Tarea no corre	Día no permitido, cuenta o programador	Ejecutar run-scheduled y revisar tarea de Windows.

Uso responsable, privacidad y seguridad

- Nunca confirmar contraseñas, tokens, claves API, perfiles del navegador ni archivos de configuración locales.
- Usar cuentas y permisos con el alcance mínimo necesario; retirar accesos cuando ya no se utilicen.
- Anonimizar correos, nombres, identificadores, órdenes y capturas antes de publicar evidencias en el portafolio.
- Revisar el historial completo de Git, no solo la última versión, antes de hacer público el repositorio.
- No automatizar login, CAPTCHA ni restricciones; usar únicamente acceso autorizado y respetar términos del sitio.
- El perfil temporal, config.json, logs y outputs contienen huellas de navegación y deben permanecer locales.

Preguntas habituales

¿Necesita iniciar sesión?

No. El diseño evita automatizar un login. Si un dato está protegido, se informa como no disponible.

¿Usa Selenium?

No. Usa Playwright conectado por CDP a un Chrome local.

¿Qué días programa?

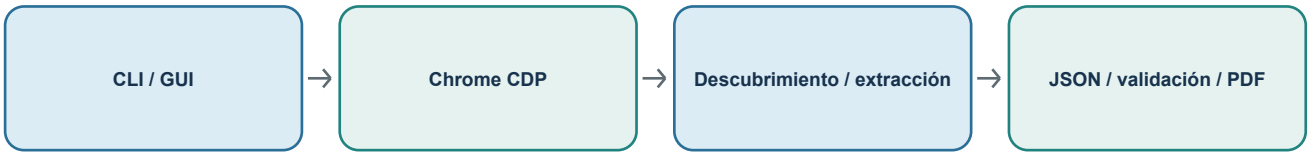
El descubrimiento programado corre jueves, viernes y sábado y apunta a jornadas de viernes, sábado y domingo.

03 · REFERENCIA TÉCNICA

Arquitectura y componentes

El CLI compone browser, checkpoint, discovery, extractor, markets, referees, validator, PDF y scheduler. El checkpoint permite reanudar; el validador impide presentar una salida parcial como completa.

Vista de arquitectura



Chrome se inicia con un perfil temporal. Playwright controla la sesión local por CDP; los datos pasan por validación antes del PDF estable.

Responsabilidad de los componentes

Componente	Responsabilidad	Tecnología o archivo
Entrada	Comandos y ventana manual	src/main.py, gui.py
Navegador	Arranque y conexión CDP	src/browser.py
Descubrimiento	Lista jornadas y partidos	src/discovery.py
Extracción	Partidos, mercados y árbitros	extractor.py, markets.py, referees.py
Estado	Checkpoint y reanudación	checkpoint.py
Salida	Validación, PDF y programación	validator.py, pdf_generator.py, scheduler.py

Configuración, datos e integraciones

Parámetros importantes

Parámetro / recurso	Uso	Tratamiento recomendado
config.json	Rutas, límites y comportamiento local	Copiar del ejemplo y excluir.
PDFTOPPM_PATH	Ruta opcional de Poppler	Variable de entorno local.
Perfil Chrome temporal	Sesión de navegador	Eliminar al cerrar; nunca versionar.
Cantidad 1–50	Tamaño manual del lote	Empezar pequeño.
Fecha / after	Jornada y hora de corte	Usar zona horaria explícita.
output / logs	Datos y diagnóstico	Ignorados y con retención limitada.

Persistencia y archivos generados

- Las corridas se agrupan en output/YYYY-MM-DD y logs; existe una copia estable bajo outputs/EcuabetExtractor.
- Todos los artefactos operativos están ignorados.
- Cada salida debe identificar fecha, fuente, versión del extractor y campos ausentes.
- No redistribuir datos sin revisar licencia y términos.

Integraciones externas

Integración	Función	Riesgo operativo
Chrome / CDP	Navegación local visible	Versión, puerto y perfil.
Sitio Ecuabet	Fuente consultada	Términos, cambios de interfaz y contenido protegido.
Playwright	Automatización del navegador	Compatibilidad con Chrome.
Poppler	Render/validación PDF	Ruta de pdftoppm.
Task Scheduler	Ejecución programada Windows	Cuenta, horario y permisos.

Flujos internos y decisiones de diseño

Extracción reanudable

1. Resolver fecha y lista.
2. Iniciar Chrome temporal y conectar CDP.
3. Extraer un partido.
4. Validar y guardar checkpoint.
5. Continuar con el siguiente.
6. Construir PDF solo con estado consistente.

Guardar después de cada unidad reduce la pérdida por cierres sin convertir datos parciales en válidos.

Programación

1. Comprobar día de ejecución.
2. Calcular jornadas objetivo.
3. Si no corresponde, terminar sin error.
4. Descubrir y procesar con límites.
5. Publicar copia estable y log resumido.

No ejecutar fuera de calendario es un resultado esperado, no un fallo.

Criterios de diseño

- Separar configuración y credenciales del código que se versiona.
- Mantener una entrada clara para operar y otra para diagnóstico o pruebas.
- Preferir fallos explícitos a continuar con datos parciales o inventados.
- Conservar trazabilidad suficiente para reconstruir qué ocurrió sin exponer información sensible.

Desarrollo, pruebas y mantenimiento

Entorno de desarrollo

- Windows, Python compatible con el proyecto y un entorno virtual dedicado.
- Dependencias instaladas desde el archivo fijado por el repositorio.
- Git para aislar cambios y conservar un historial verificable.

```
pytest
python -m src.main test --matches 5 --after 13:00
python -m src.main validate
python -m src.main build-pdf
```

Estrategia de pruebas

- Ejecutar las 17 pruebas offline.
- Probar cambios de selector con máximo cinco partidos.
- Cubrir corte de Chrome, reanudación, campo ausente y PDF inválido.
- Verificar que no se invoca login ni se fabrica un mercado.

Registro, diagnóstico y soporte

- Conservar el mensaje completo y la hora del evento; evitar capturas que muestren credenciales o datos personales.
- Distinguir un error local de un fallo del servicio externo comprobando conectividad, permisos y cuotas.
- Repetir el caso con una entrada pequeña y controlada antes de cambiar dependencias o borrar datos.

Mantenimiento recomendado

- Revisar dependencias y servicios externos de manera periódica, probando la actualización en una rama separada.
- Actualizar este manual cuando cambien comandos, configuración, estructura de datos o flujo de usuario.
- Mantener ejemplos sin secretos y una prueba mínima que permita validar la instalación.
- Etiquetar versiones estables y documentar las alternativas como ramas, no como reemplazos ambiguos.

Despliegue y continuidad

Ruta de despliegue

1. Clonar o copiar una versión etiquetada en un equipo de prueba.
2. Crear un entorno virtual nuevo e instalar dependencias desde el archivo del proyecto.
3. Aplicar configuración local y credenciales fuera de Git.
4. Ejecutar una prueba pequeña; revisar salida, datos y registros.
5. Habilitar el acceso al usuario final solo después de la validación.

Respaldo y recuperación

- Respaldar solo datos necesarios y cifrar cualquier copia que contenga información personal u operativa.
- Probar la restauración en una ubicación distinta antes de confiar en el respaldo.
- Conservar una copia de la configuración sin secretos y registrar por separado dónde se administran las credenciales.

Criterios de aceptación

- Una instalación limpia puede completar el recorrido principal descrito en este manual.
- Los errores de credenciales, permisos o red se informan sin filtrar secretos.
- Los archivos temporales y los datos generados permanecen fuera del repositorio.
- La persona responsable puede identificar versión, configuración y evidencia de la última ejecución correcta.

Límites conocidos y evolución

Límites de la versión documentada

- Depende de estructura y disponibilidad de un sitio externo.
- No recupera contenido que requiere autenticación.
- La ejecución programada requiere Windows, Chrome y sesión adecuadamente configurados.
- La extracción puede quedar parcial; el validador debe comunicarlo.

Hoja de ruta sugerida

Prioridad	Mejora	Resultado esperado
Alta	Pruebas de selectores con HTML anonimizado	Detectar cambios sin consultar el sitio continuamente.
Alta	Límites, backoff y resumen de campos ausentes	Operación respetuosa y diagnóstico claro.
Media	Manifiesto de cada corrida	Registrar versión, fecha y huellas.
Media	Instalador verificable de tarea programada	Facilitar alta y baja sin tareas huérfanas.

Versiones y ramas

Rama / versión	Papel en el historial	Recomendación
main · Chrome CDP	Línea oficial	Usar para operación local autorizada.
Modo manual	Selección explícita sin modificar tareas	Ruta recomendada para pruebas y demostración.
Modo programado	Calendario jueves–sábado	Habilitar solo tras validar manualmente.

Entrega a otra persona

Este apartado resume lo mínimo que debe conocer quien reciba el mantenimiento. La intención es que el proyecto pueda retomarse sin depender de la memoria del autor.

Paquete de traspaso

- Repositorio, rama y etiqueta exacta que se consideran estables.
- Lista de servicios externos, responsables de las cuentas y procedimiento para rotar accesos.
- Configuración de ejemplo sin secretos y ubicación de los datos persistentes.
- Resultado de la última prueba, limitaciones abiertas y próximos cambios recomendados.
- Un caso de prueba anonimizado que permita recorrer el flujo de principio a fin.

Glosario breve

Término	Significado en este proyecto
CDP	Protocolo de depuración usado para controlar Chrome local.
Checkpoint	Estado guardado para reanudar una corrida.
Discovery	Etapa que identifica jornadas y partidos.
Campo ausente	Dato no disponible; no equivale a cero.
Poppler	Herramientas usadas para procesar o renderizar PDF.

Cierre

> *La mejor señal de madurez no es que el proyecto nunca falle, sino que otra persona pueda instalarlo, entender sus límites y recuperar una operación sin improvisar.*

Documento mantenido junto al código fuente. Las decisiones operativas que cambien el comportamiento deben reflejarse tanto en el código como en esta guía.